

Lineer Regresyon Log Dönüşümünde Neden Sapıtıyor?

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \tilde{y}_i)^2$$

$$MSE_{\text{transformed}} = \frac{1}{n} \sum_{i=1}^n (\ln(y_i) - \ln(\tilde{y}_i))^2$$

$$MSE_{\text{transformed}} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i}{\tilde{y}_i} - 1 \right)^2$$

Örnek 1 prediction=2 real=1
y=e^2= 7.39
y'=e=2.72
Squared Error=21,8

y_transformed=ln e^2=2
y'_transformed=ln e=1
Squared Error_transformed=1

Örnek 2
prediction=5 real=2
SE=19888
SE_transformed=3

Yukarıdaki 2 gözlem üzerinden logaritma dönüşümünde MSE kullanmanın nasıl sonuçlar doğuracağını anlatacağım.

Diyelim ki transformed SSE için hatayı 2 azaltacağız.

1.yol: Örnek 1'i 1 azalt, Örnek 2'yi 1 azalt

Gözlem 1 için yeni prediction=1, yeni SE_transformed=0, yeni SE=0

Gözlem 2 için yeni prediction=4, yeni SE_transformed=2, yeni SE=2289

2.yol: Örnek 1 sabit, Örnek 2'yi 2 azalt

Gözlem 1 için hata ve tahmin aynı

Gözlem 2 için yeni prediction=4, yeni SE_transformed=2, yeni SE=161

1.yolda gerçek SSE düşüşü: 17620

2.yolda gerçek SSE düşüşü: 19749

Drift ekleyememekten daha büyük bir sorun



Küçük rakamlara ve sadece 2 rakama rağmen 2 bin civarı toplam hata değişebiliyor ve lineer regresyon için bu iki değişim de aynı. LR için toplam hata değişimi 2 durumda da 2. MSE kullanmanın yarattığı sorunu gidermek için exponential loss kullanmak çözüm olabilir.

Eren Exponential Cost Function:

$$\frac{1}{n} \sum_{i=1}^n \left(e^{\frac{y_i}{\tilde{y}_i}} - e^{ax+b} \right)^2$$

e ile y'leri yer değiştirdiğimizde orjinal MSE'yi elde ettiğimizi göreceğiz. Lineer

Çözdüğüm örnekteki SSE değişimini exponential cost functiona göre hesaplırsak SSE değişimi olmadığını göreceğiz.

Hessian matriksini incelediğimde X>1 için konveks olduğunu görüyorum

Powelde kullandığımız MSE tek lokal minimuma sahipti ama konveks değildi

Sonuç eren costu optimize etmek çok daha kısa sürebilir.